Previsão do preço da gasolina com redes recorrentes (ANP)

Resultados: SimpleRNN, GRU e LSTM

Disciplina: Deep Learning – Professor: Dr. Sérgio Canuto

Alunos: Robson Pereira da Silva e Ivânio José da Rocha Júnior

Repositório: github.com/robsonps-desv/previsao-gasolina-anp-rnn

Gemini Notebook

Formulação do Problema e Contexto dos Dados

Objetivo:

Regressão one-step-ahead (janela de w semanas → preço em t+1).

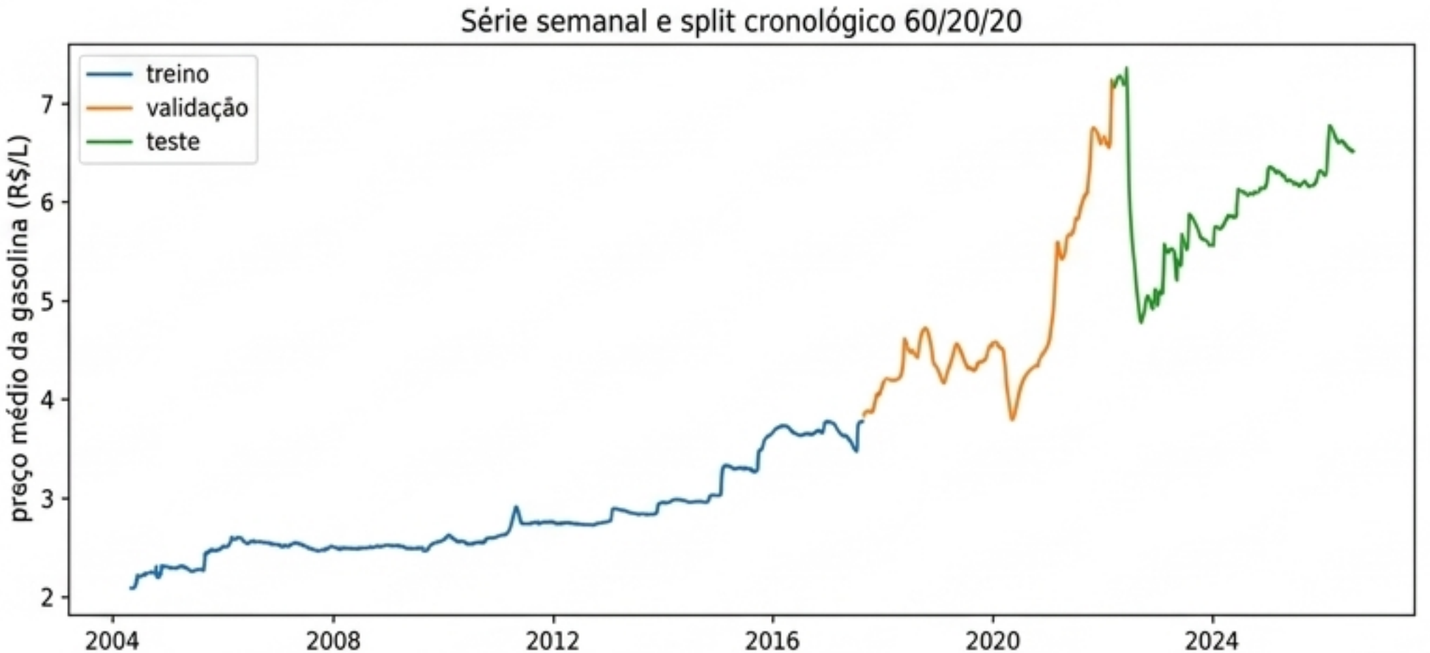
Série ANP:

Dados oficiais, nível nacional (2004–2026). Total de 1.152 semanas.

8 Features (Variáveis):

Gasolina: preço médio, mínimo, máximo, desvio padrão, coef. de variação, nº de postos.

Etanol e Diesel: preço médio.



O Desafio Estrutural: O preço médio quase triplica entre o final do período de treino (linha azul) e o período de teste (linha verde).

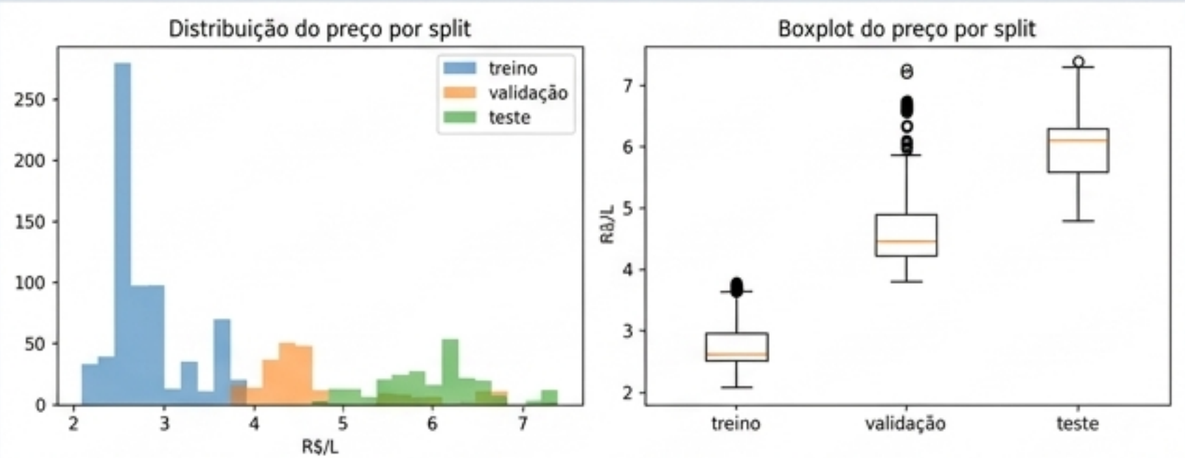
Gemini Notebook

Comportamento da Série e Mudança de Patamar

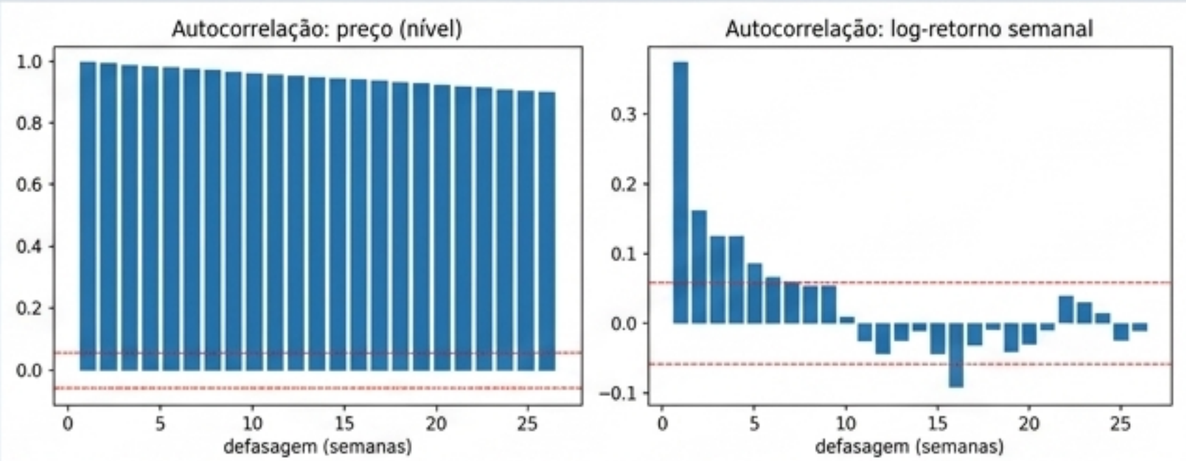
Treino	Validação	Teste
2,62 R$/L	**4,47 R$/L**	**6,10 R$/L**
(Máximo: 3,78 R$/L)		(Mínimo: 4,79 R$/L)
Mediana	Mediana	Mediana

Insight: O máximo absoluto do treino é inferior ao mínimo do teste.

Distribuição e Boxplot do Preço



Autocorrelação



A **Força da Persistência:** Alta inércia com autocorrelação de nível em 0,997 (defasagem 1). Os retornos curtos têm caudas pesadas (curtose 12 a 60). Repetir a última semana será o baseline formidável a ser batido.

Gemini Notebook

Protocolo Experimental Rigoroso

Split Temporal

60/20/20 estritamente cronológico. Alvos restritos ao seu próprio período, com fronteiras rigidamente corrigidas.

Normalização Blindada

StandardScaler ajustado exclusivamente no conjunto de treino.

Zero vazamento de dados futuros.

Configuração de Treino

$w \in \{4, 12, 26\}$ semanas.

Otimizador Adam, Loss MSE, Batch Size 32, Early Stopping (paciência 15).

Métricas e Avaliação

Principal: MAE (R$/L)

Complementares: RMSE e R^2

O **Baseline de Referência** é o Modelo Ingênuo de Persistência ($\hat{y}_{t+1} = y_t$).

Gemini Notebook

Modelos Avaliados e Busca de Hiperparâmetros

Custo Computacional vs. Capacidade (Considerando 64 unidades)			
	Modelo	**Custo (Parâmetros)**	**Nota**
1	SimpleRNN	4.737 parâmetros	Rápida, base arquitetural.
2	GRU	14.273 parâmetros	Equilíbrio computacional (portas de atualização/reset).
3	LSTM	18.753 parâmetros	Alta capacidade (4x os parâmetros da SimpleRNN).

A Busca Optuna

Otimização focada no MAE de validação:

- Unidades: 16 a 128
- Camadas: 1 ou 2
- Dropout: 0 a 0,5
- Learning Rate e Batch Size

Vencedor da Etapa 1: GRU

O Optuna selecionou uma GRU com 96 unidades, 2 camadas e batch 64.

MAE de validação alcançado: 0,435 R$/L.

Gemini Notebook

Etapa 1: A Falsa Promessa da Validação

O Desempenho:

- A rede GRU liderou as janelas base (MAE 0,742 vs. LSTM 0,872).
- O Optuna aprimorou a GRU para excelentes 0,435 R$/L na validação.

A Queda no Teste

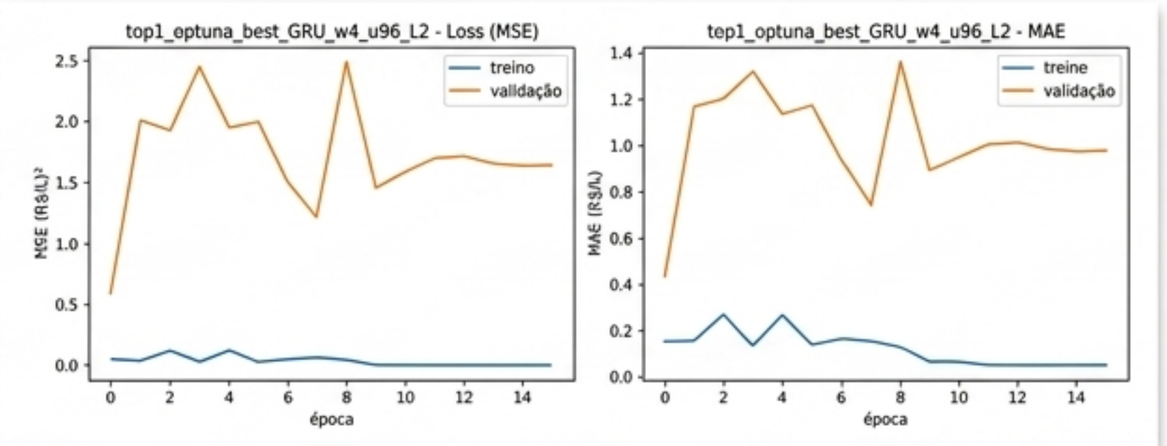
GRU (Optuna):

MAE: 1,322 R$/L

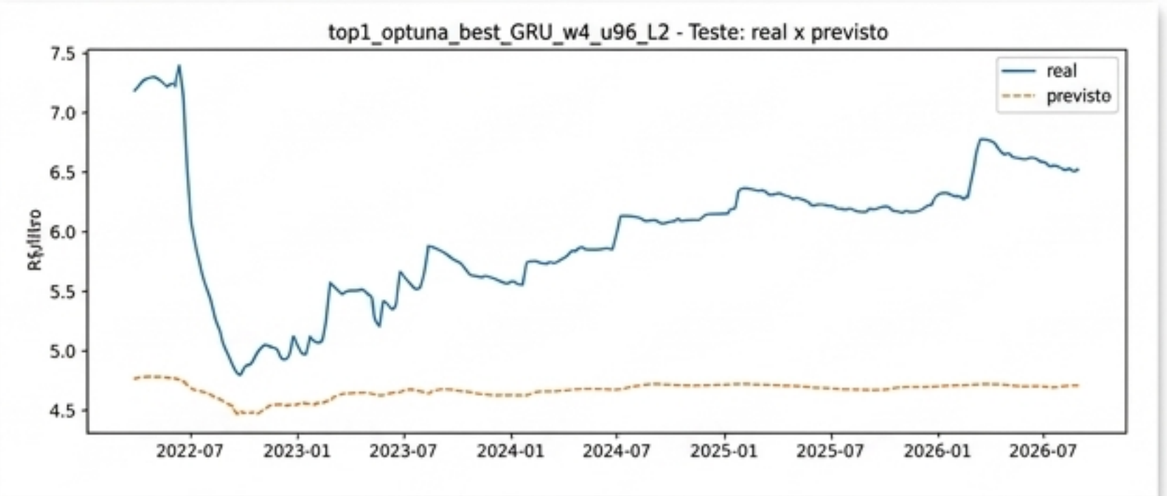
R^2: −5,265

Persistência (Baseline):

MAE: 0,0390 R$/L



Diagnóstico Primário: O gráfico de previsão (linha tracejada) forma uma reta horizontal inútil, distante e alheia à realidade da curva de preços do teste.



Diagnóstico Primário: O gráfico de previsão (linha tracejada) forma uma reta horizontal inútil, distante e alheia à realidade da curva de preços do teste.

Gemini Notebook

Autópsia da Falha: Saturação Matemática

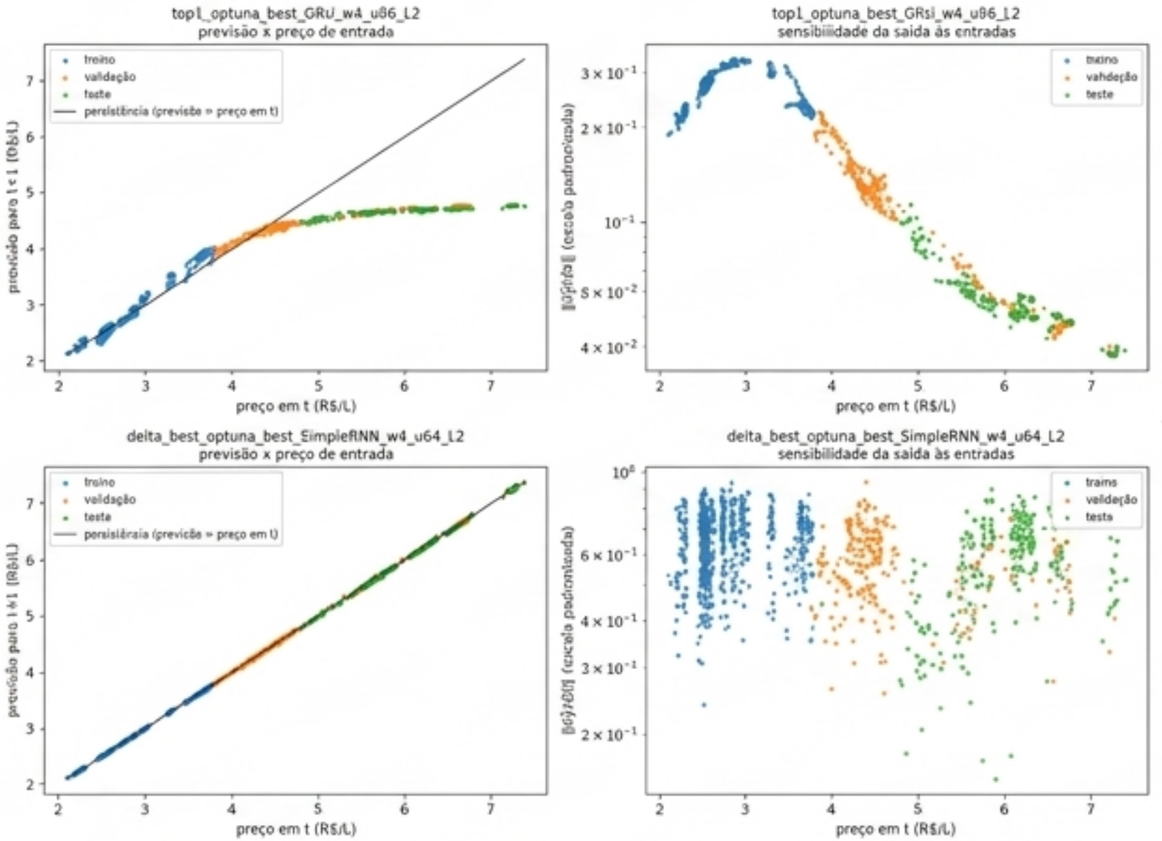
Analytical Causal Logic

O Fato: O preço real durante o teste atingiu de 4,6 a 10,7 desvios padrão acima da média vista no treino.

O Efeito Matemático: As funções de ativação limitadas (sigmoide e tanh) das portas GRU saturam irreversivelmente com entradas dessa magnitude.

A Evidência: A sensibilidade da saída à entrada ($\partial\hat{y}/\partial X$) despencou de 0,28 no treino para irrelevantes 0,054 no teste.

Visual Proof of Mathematical Saturation



O colapso não foi bug ou vazamento de dados. Foi a quebra de estacionariedade destruindo a capacidade de resposta da rede em dados Out-of-Distribution.

Gemini Notebook

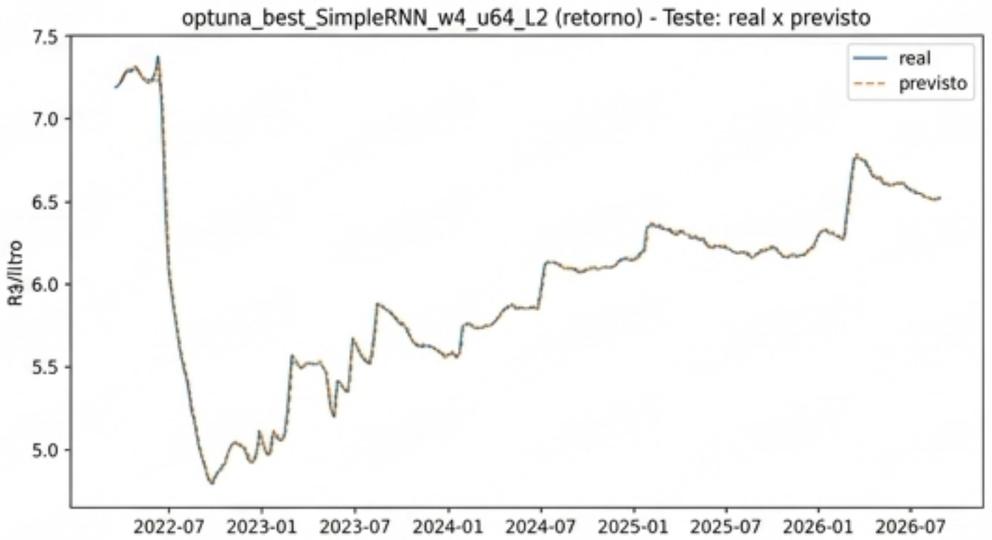
Etapa 2: Recuperando o Modelo com Estacionariedade

A Reformulação: `Features` e o `alvo` foram convertidos para log-retornos semanais.
O preço absoluto é reconstruído iterativamente.

O Impacto Monumental

O **MAE de teste desabou ~97%**: De 1,322 R$/L para impressionantes 0,0412 R$/L (usando a SimpleRNN Optuna).

O **R^2 saltou de negativo para 0,9804**.



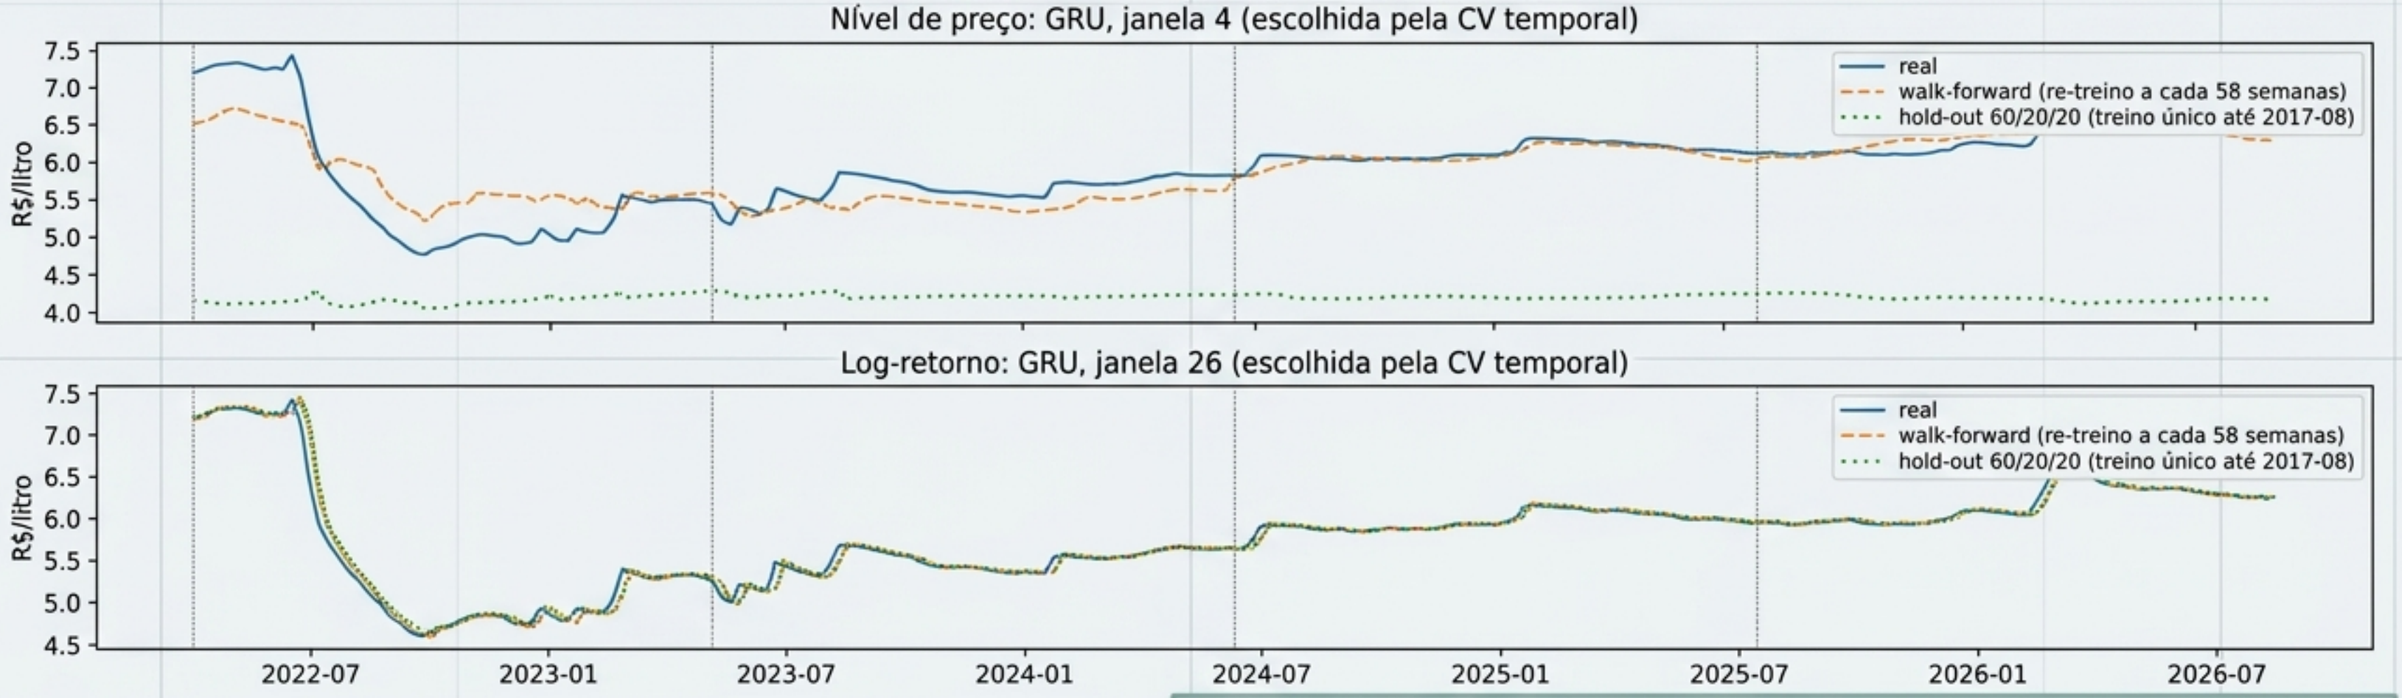
Novo Ranking:

- Com a série **estacionária**, a arquitetura mais leve (SimpleRNN) superou GRU e LSTM na validação principal.
- As redes voltaram a operar em nível **competitivo** com o baseline de **Persistência** (0,0390 R$/L).

Gemini Notebook

Simulando Produção: Walk-Forward e Re-treino

O Cenário Real: Uso de *TimeSeriesSplit* nas 232 semanas de teste com re-treino a cada 58 semanas. Não faz sentido usar em 2026 um modelo treinado até 2017.



Em Nível de Preço:
Re-treinar corta o erro massivamente (79-92%), mas ainda fica **4,6x** pior que a persistência.

O Empate Técnico:
Em **log-retornos**, a GRU (janela 26, eleita via CV) alcança MAE **0,0389** e RMSE **0,0748**.
Ela empata com a persistência no erro absoluto e a supera em **8%** no erro quadrático (RMSE).

Gemini Notebook

Análise Estrutural: Capacidade vs. Custo

SimpleRNN

A opção mais leve, rápida e barata. Venceu a validação de log-retornos provando ser altamente custo-efetiva para séries com dependência curta.

GRU e LSTM (Redes com Portas)

Portas não entregaram vantagem estrutural em hold-outs curtos. Na Validação Cruzada Temporal, demonstraram ligeira vantagem competitiva, mas mantiveram empate técnico entre si.

Considerações de Capacidade

A LSTM básica (64 unidades) não justificou seu peso computacional contra as outras, necessitando de 128 unidades apenas para competir.

Janelas Temporais:

Janelas curtas (4 semanas) fornecem generalização idêntica ou superior a janelas longas (12 ou 26). Dependências muito longas não justificaram o custo nesta série.

Gemini Notebook

Conclusões Gerais e Limitações do Estudo

Principais Descobertas:

- **O Triunfo da Representação**: O correto tratamento matemático dos dados (estacionariedade via log-retornos) gerou um ganho infinitamente maior que a escolha arquitetural ou a hiperparametrização.
- **A Força da Simplicidade**: Apesar de todo o aparato de Deep Learning, as redes apenas empatam com ou se aproximam levemente do modelo ingênuo de persistência.

Limitações Metodológicas Reconhecidas:

- Validação baseada em apenas uma seed por configuração de treino.
- Amostragem total pequena para modelos de Deep Learning (~680 sequências efetivas de treino).
- A Validação Cruzada (CV) foi aplicada de maneira restrita, focada essencialmente na grade principal de hiperparâmetros.

Gemini Notebook